

判决反馈递归神经网络自适应均衡器研究

莫 玮¹, 蒋洪睿², 谢维信¹, 李 丽²

(1. 西安电子科技大学 电子工程学院 陕西 西安 710071; 2. 桂林电子工业学院 广西 桂林 541004)

摘要: 针对存在严重符号间串扰及轻度非线性畸变的数字信道,提出了两种判决反馈递归神经网络均衡器结构,将传统的线性信道判决反馈结构巧妙地融入递归神经网络中,在自适应训练时用期待信号代替判决反馈信号,并对学习步长自适应调节进行了研究.实验结果表明:在自适应参数数目相同的情况下,该均衡器较传统的递归神经网络均衡器具有更好的特性.

关键词: 递归神经网络;自适应均衡;判决反馈

中图分类号: TN911.5 **文献标识码:** A **文章编号:** 1001-2400(1999)05-0627-05

Study of the decision feedback recurrent neural network equalization with the self-adjusting structure

MO Wei¹, JIANG Hong-rui², XIE Wei-xin¹, LI Li²

(1. School of Electronic Engineering, Xidian Univ., Xi'an 710071, China; 2. Guilin Institute of Electronic Technology, Guilin 541004, China)

Abstract Two decision feedback equalizer structures using recurrent neural networks for non-linear channels with severe Inter Symbol Interference (ISI) and mild non-linear distortion are proposed, which put the traditional decision feedback structure for linear channels equalization skillfully into the recurrent neural networks, substitute the training signal for the decision feedback signal in the learning process and adaptively adjust the learning step. Simulation results of the first type of two new equalizer structures have shown that it has better equalization performance than the traditional recurrent neural network equalizer with the same number of parameters.

Key Words recurrent neural networks; adaptive equalization; decision feedback

信道均衡是用来消除码间干扰,对信道畸变进行补偿,从而在接收端正确重建发送信号的滤波方法.由于信道均衡可以看作是一个模式分类问题,而神经网络具有良好的模式分类特性,因此,随着神经网络技术的发展,人们开始采用不同结构的神经网络来实现信道的自适应均衡^[1~2].就自适应均衡器的不同结构、不同算法而言,各具特色,各有优劣.例如,多层感知器只要自由度足够,就能进行任意复杂的非线性信道均衡.但在工程实现中,其性能与实现的复杂程度往往构成一对尖锐的矛盾.结构越庞大,运算时间就越长,就越阻碍数据传输率的提高.递归神经网络 (Recurrent Neural Networks, RNN)具有规模小、性能优的特点,递归神经网络均衡器 (Recurrent Neural Networks Equalizer, RNN E)在信道均衡中

收稿日期: 1999-01-20

基金项目: 军事电子预研基金资助项目 (DJ4. 7. 1. 3)

作者简介: 莫 玮 (1956-),男,教授,西安电子科技大学博士生.

大大缓解了上述矛盾.由于 RNN 的属性类似于 IIR 滤波器,故其在信道补偿中,只需很少的结点就可达到较好的均衡效果,即完成比较复杂的非线性映射.但因各结点的输出均要参加反馈又导致了 RNN 稳定性差和一致性差的缺点.引入判决反馈结构可以克服这一缺点^[3].在存在较严重码间干扰且具有适度非线性失真的非线性信道中,该文将判决反馈结构融入到 RNN 中,形成两种的判决反馈递归神经网络均衡器(简称 DFRNNE)结构.针对结构 1,该文采用了实时递推学习算法(Real-Time Recurrent Learning algorithm, RTRL),并对学习步长进行自适应调节.

1 DFRNNE 的两种结构

图 1 是具有 3 个结点的 RNN 结构图,其中各神经元都相互连接,任一个输入都要进入各神经元,每一个神经元的输出都可作为该网络之外输出.图 2 是串行输出的 DFRNNE 结构(简称 S-DFRNNE),图 3 是并行输出的 DFRNNE 结构(简称 P-DFRNNE).




图 1 3 个结点的 RNN 结构




图 2 S-DFRNNE 结构




图 3 P-DFRNNE 结构

对于图 2 所示的 S-DFRNNE,其各部分数学表达式为

$$v_p(t+1) = \sum_{i=1}^n w_{pi} y_i(t) + \sum_{i=1}^m w_{p,m+i} x_{k-i+1}(t) + \sum_{i=1}^l w_{p,m+m+i} \hat{s}_{k-d-i},$$

$$y_p(t+1) = f[v_p(t+1)] \quad , \quad p = 1, 2, \cdots, n \quad ,$$
$$f(x) = \frac{1 - \exp(-2x)}{1 + \exp(-2x)} \quad ,$$
$$\hat{s}_{k-d} = \operatorname{sgn}(y_n(t+1)) \quad .$$

式中 v_p 为第 p 个结点的输入加权和; y_p 为第 p 个结点的输出; d_h ($h = 1, 2, \cdots, n$) 为期待响应或训练信号; n 为递归神经网络的内部结点数; m 为量化信号对均衡器的延迟输入数; l 为均衡器的判决反馈延迟输入数; d 为信道的时延量; w_{pi} 为第 i 个结点到第 p 个结点的权值 ($p, i = 1, 2, \cdots, n$); w_{pj} 为各延迟输入信号到第 p 个结点的权值 ($j = n+1, \cdots, n+m$); w_{ph} 为各判决反馈延迟信号到第 p 个结点的权值 ($h = n+m+1, \cdots, n+m+l$). 令 d_n 等于 \hat{s}_{k-d} , 训练时开关 K 指向 1, 让训练信号充当各判决反馈延迟输入, 以充分利用有效信息防止错误传播; 信号传播期间, 开关 K 指向 2, 均衡器的判决输出 $\operatorname{sgn}(y_n)$ 进入各反馈延迟输入.

对于图 3 所示的 P-DFRNN E, 其各部分数学表达式除 $v_p(t+1)$ 不同于 S-DFRNN E 外, 其余均与 S-DFRNN E 各部分数学表达式相同, 下面给出 P-DFRNN E 的 $v_p(t+1)$ 表达式

$$v_p(t+1) = \sum_{i=1}^n w_{pi} y_i(t) + \sum_{i=1}^m w_{p, n+i} x_{k-i+1}(t) + \sum_{i=1}^l w_{p, n+m+i} \hat{s}_{k-d-1, i} \quad ,$$

其中 $\hat{s}_{k-d-1, i}$ 为第 i 个结点判决反馈时延为 $d+1$ 的输入 ($i = 1, 2, \cdots, n$).

2 DFRNNE的学习算法

2.1 RTRL算法

采用 RTRL(Real-Time Recurrent Learning)算法来调节两种结构的均衡器权值, 针对两种均衡器结构其表达式稍有不同. 定义第 h 个神经元的误差为

$$e_h(t+1) = d_h(t+1) - y_h(t+1) \quad , \quad (h = 1, \cdots, n) \quad ,$$

网络的瞬时总误差为 $J(t+1) = \frac{1}{2} \sum_{h=1}^n e_h^2(t+1)$,

算法的目的是调整联结权 w_{ij} 的值以使 $J(t+1)$ 达最小. 定义“灵敏度”为

$$p_{ij}^p(t) = \frac{\partial v_p(t)}{\partial w_{ij}} \quad ,$$

对 S-DFRNN E, 有

$$p_{ij}^p(t+1) = f'(v_p(t+1)) \left[\sum_{h=1}^n w_{ph}(t) p_{ij}^h(t) + W_p z_j(t) \right] \quad ,$$

$$w_{ij}(t+1) = w_{ij}(t) + T \sum_{h=1}^n e_h(t+1) p_{ij}^h(t+1) \quad ,$$

$$T > 0, \quad i = 1, 2, \cdots, n, \quad p = 1, 2, \cdots, n \quad ,$$
$$j = 1, 2, \cdots, n, n+1, \cdots, n+m, n+m+1, \cdots, n+m+l \quad ,$$

其中

$$W_p = \begin{cases} 1, & i = p \quad , \\ 0, & i \neq p \quad , \end{cases} \quad f'(x) = \frac{4}{[\exp(x) + \exp(-x)]^2} \quad .$$

$z_j(t)$ 分别代表 S-DFRNN 的内部结点输出 ($j = 1, 2, \cdots, n$ 时), 外输入信号 ($j = n+1, \cdots, n+m$ 时) 及反馈输入信号 ($j = n+m+1, \cdots, n+m+l$ 时), T 为自适应过程的学习步长.

对 P-DFRNN E, 其表达式与 S-DFRNN E 相同, 只是 $j = 1, 2, \cdots, n, n+1, \cdots, n+m, n+m+1, \cdots, n+m+l$.

2.2 学习步长自适应调节

学习步长 T 对算法的收敛速度有一定影响. 该文采用自适应调节 T 值的方法. 其基本思想是每次迭代后不断自适应调节 T 值, 一方面使算法尽快跳出局部最小, 加速其收敛过程, 另一方面避免算法产生

不稳定现象.

自适应调节方法 1:

将 T 的调整用一个指数函数来实现,此函数以总误差 En (即对部分或全部样本,系统的总误差 $EJ(t+1)$)作为自变量.取 $T = T_0 \exp(-En)$,其中 $0.1 < T_0 < 1.5$.

算法将在迭代过程中对 T 进行自适应调节.若总误差较大,则 T 较小;若总误差较小,则 T 较大.随着迭代次数增加总误差变小, T 逐渐保持一定水平.当输入样本特征数较大时,在迭代初期误差较大,此时 T 取较大值时容易使权值变化量越变越大而导致迭代过程发散.该方法一开始对 T 进行一定的抑制,这样可改善算法的收敛性能,从而具有广适性.

自适应调节方法 2

引入动量因子 u ($0 < u < 0.001$) 对权值进行调整,表达式为

$$w_{ij}(t+1) = w_{ij}(t) + T \sum_{h=1}^n \alpha_h(t+1) p_{ij}^h(t+1) + u(w_{ij}(t) - w_{ij}(t-1)) \quad ,$$

其理论根据是假设理想权值为一常矢量.

3 仿真研究

针对 S-DFRNN,笔者在同等的条件下将它与传统的 RNN 做仿真实验并进行了比较.

3.1 学习特性的比较

采用以下失真信道模型^[4]

$$\begin{aligned} \text{LCH } X_k &= 0.3482 S_k + 0.8704 S_{k-1} + 0.3482 S_{k-2} \quad , \\ \text{NLCH } Y_k &= X_k + 0.2 X_k^2 \quad , \end{aligned}$$

其中 LCH 所描述的线性失真信道具有较严重的码间干扰, NLCH 所描述的信道具有适度的非线性失真.仿真实验中,在均衡器接收端加入功率为 ϵ^2 的高斯白噪声,让 S_k 为取 $-1, +1$ 等概的,功率为 1 的随机序列,自适应迭代采用实时递归学习 (RTRL) 算法.每一次实验时,初始权值 w_{ij} , 初始灵敏度 p_{ij}^h 及各结点的初始输出值 y_p 均取为绝对值小于等于 10^{-3} 的随机数.对于 RNN 及 S-DFRNN 两种结构,其参数分别取为 $m=2, n=1, T=0.5$ 及 $m=2, n=1, l=3, T_0=0.5$, 两者可调参数均为 6. 于是对两种不同的失真信道得到两组学习曲线 (独立运行 50 次后的平均结果).

图 4 中, 浊化信道为线性失真信道 LCH 与非线性失真信道 NLCH 级联而成, 且 $R_{SN} = 18 \text{ dB}$. 观察图 4 可知, S-DFRNN 收敛大约在 -30 dB , 而 RNN 在 -10 dB 左右有发散的趋势. 比较之下, S-DFRNN 比传统的 RNN 有更小的稳态均方误差 Y_{MSE} .




图 4 学习曲线 (信道: LCH+ NLCH)




图 5 比特误码率曲线 (信道: LCH+ NLCH)

3.2 比特误码率曲线比较

为了全面考察 S-DFRNN 的性能,针对图 4所考察的失真信道,测出比特误码率曲线如图 5所示.测试中由 d_k 先训练 2 000次 ($e_k = d_k - y_k$),然后在数据传输状态下测试比特误码率.训练时各种初始值的设置同前所述,RNNE和 S-DFRNN 的参数仍分别设置为 $m = 2, n = 1$ 及 $m = 2, n = 1, l = 3$,两种结构都具有 6个可调参数.传输过程用 8 000个数据进行测试,每一个 R_{SN} 值对应一个 R_{BE} 值(独立运行 50次后的平均结果).

由图 5所示曲线可知,S-DFRNN 比 RNNE有更好的比特误码率 R_{BE} 改善.在仿真过程中,发现给定的两个失真信道中,RNNE的 R_{BE} 均呈现出非一致性并有一定的摆幅,对于不同的 R_{SN} 性能时好时坏,甚至其 R_{BE} 随 R_{SN} 增大而恶化,这是 RNNE在信道均衡中不尽完善之处,而 S-DFRNN 则弥补了这一不足,它的 R_{BE} 特性具有一致性.

4 结 论

由于 RNNE的均衡性能对各种初始值的设定极其敏感.如何选定初始值至今尚无定论,这也是大多数神经网络自适应均衡器存在的问题,这里 RNNE尤为突出.但 S-DFRNN 因其对各种初值的设置并不敏感,从而易于实时处理,在自适应训练时只需将各种初值设置为较小的随机数,适当选择自适应步长,即可得到较好的均衡效果,学习曲线和误码曲线的一致性,充分支持了这一点.

由以上讨论可知,对于存在较严重码间干扰和适度非线性失真的非线性信道,采用 S-DFRNN 可以取得比 RNNE更好更稳定的均衡性能,既具备 RNNE可调参数少的优点,又发挥了判决反馈结构抑制码间干扰的优势,这对工程实施是一个可取的方案.另外,该文给出了 P-DFRNN 的结构与算法,它可以在输出端并行输出信号,而硬件开销与 S-DFRNN 近似相等.这可以节省时间,从而提高硬件的利用率.在实际应用中,也不失为一种优选的自适应均衡器.

参考文献:

[1] Gibson G J, Su S, Cowan C F N. Multilayer Perceptron Structures Applied to Adaptive Equalisers for Data Communications[A]. Proc IEEE Internat Conf Acoust Speech Signal Processing[C]. New York: IEEE ASSPA, 1989. 1 183 ~ 1 186

[2] Cha I, Kassam S A. Channel Equalization Using Adaptive Complex Radial Basis Function Network[J]. IEEE Journal on SAC, 1995, 13(1): 122~ 131.

[3] Chen S, Mulgrew B, McLaughlin S. Adaptive Bayesian Equalizer with Decision Feedback[J]. IEEE Trans Signal Processing, 1993, 41(9): 2 918~ 2 927.

[4] 何培宇,王永德. 一种结构自适应的非线性信道神经网络均衡器[J]. 四川大学学报, 1996, 33(4): 405~ 409.

(编辑: 高东娟)